

USO DE INTELIGÊNCIA ARTIFICIAL PARA DETECÇÃO DE TUMORES CEREBRAIS

Caio H. F. Feitosa¹

Samuel B. Paiva²

Francisco D. B. S. Praciano³

RESUMO

Com os avanços tecnológicos, a Inteligência Artificial (IA) tem se consolidado como uma ferramenta essencial na medicina, especialmente na detecção e tratamento de tumores cerebrais. Utilizando técnicas como redes neurais convolucionais (CNNs), a IA tem demonstrado alta precisão na análise de imagens médicas, superando limitações do diagnóstico humano, como a variabilidade entre especialistas. Este trabalho tem como objetivo desenvolver um modelo de CNN, utilizando a biblioteca PyTorch, para classificar automaticamente imagens de ressonância magnética cerebral. A arquitetura proposta conta com três blocos convolucionais seguidos de camadas totalmente conectadas, e foi treinada com dados obtidos no Kaggle, contendo imagens com e sem tumor. As simulações incluíram redimensionamento das imagens, uso do otimizador Adam e da função de perda CrossEntropyLoss. Os resultados foram avaliados por métricas como acurácia, precisão, recall, demonstrando o potencial da IA na melhoria do diagnóstico precoce e no combate aos tumores cerebrais.

¹ Instituto Federal de Educação, Ciência e Tecnologia do Ceará - Campus Jaguaribe
Tecnólogo em Redes de Computadores
caio.feitosa09@aluno.ifce.edu.br

² Instituto Federal de Educação, Ciência e Tecnologia do Ceará - Campus Jaguaribe
Doutor em engenharia elétrica e de computação
samuel.paiva@ifce.edu.br

³ Universidade Federal do Ceará - LSBD
Mestre em Ciência da Computação
daniel.praciano@ifce.edu.br

Palavras-chave: Inteligência Artificial (IA); Redes Neurais Convolucionais (CNNs); Classificação de Imagens; Detecção de Tumores Cerebrais; Ressonância Magnética;

ABSTRACT

With technological advancements, Artificial Intelligence (AI) has become an essential tool in medicine, especially in the detection and treatment of brain tumors. Using techniques such as Convolutional Neural Networks (CNNs), AI has shown high accuracy in the analysis of medical images, overcoming limitations of human diagnosis, such as inter-specialist variability. This study aims to develop a CNN model using the PyTorch library to automatically classify brain MRI images. The proposed architecture consists of three convolutional blocks followed by fully connected layers and was trained with data from Kaggle containing images with and without tumors. The simulations included image resizing, the use of the Adam optimizer, and the CrossEntropyLoss function. The results were evaluated using metrics such as accuracy, precision, and recall, demonstrating the potential of AI in improving early diagnosis and fighting brain tumors.

Keywords: Artificial Intelligence (AI); Convolutional Neural Networks (CNNs); Image Classification; Brain Tumor Detection; Magnetic Resonance Imaging (MRI);

1 INTRODUÇÃO

Com o avanço acelerado da tecnologia, diversos setores têm se adaptado para incorporar inovações que otimizam processos e melhoram resultados. Na medicina, esse progresso é especialmente significativo e importante para a sociedade, com a Inteligência Artificial (IA) emergindo como uma ferramenta revolucionária. Ao simular redes neurais humanas por meio de sistemas computacionais, especialmente por meio de uma técnica chamada redes neurais artificiais que busca imitar o funcionamento do cérebro humano. Assim como o cérebro é composto por bilhões de neurônios interconectados, as redes neurais artificiais são formadas por "nós" ou "neurônios" virtuais distribuídos em camadas. Esses nós recebem informações, realizam cálculos matemáticos e transmitem os resultados a outros nós, de maneira semelhante aos impulsos elétricos no cérebro, essa tecnologia tem auxiliado em diversas áreas médicas, desde a análise de exames para detecção de doenças até a personalização de tratamentos.

Dentre as aplicações mais relevantes da IA na medicina, destaca-se o combate aos tumores cerebrais, um grave problema de saúde pública devido à sua complexidade e à alta taxa de mortalidade quando não diagnosticados precocemente. A detecção rápida e

precisa é crucial para aumentar as chances de sucesso no tratamento, tornando a IA uma aliada fundamental nesse processo

2 JUSTIFICATIVA E OBJETIVOS

O estudo da implementação de uma arquitetura baseada em CNNs para o reconhecimento de tumores cerebrais é essencial para auxiliar na detecção precoce, tendo em vista que uma das limitações do diagnóstico tradicional é a variabilidade entre especialistas, ou seja, diferentes radiologistas podem apresentar discordâncias significativas em seus diagnósticos devido a fatores como experiência clínica ou até mesmo viés cognitivo, um fator que pode ser reduzido pelo uso de modelos de aprendizagem de máquina por se tratar de uma ferramenta de reconhecimento de padrões.

A identificação precoce de doenças permite intervenções terapêuticas mais eficazes, o que pode aumentar significativamente as taxas de sobrevivência e melhorar a qualidade de vida dos pacientes (World Health Organization, 2020). Assim, o uso desses modelos pode reduzir a variabilidade subjetiva do diagnóstico humano, garantindo maior confiabilidade na detecção de lesões pequenas ou em regiões anatomicamente complexas.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 Tumores Cerebrais

Tumores cerebrais são massas anormais localizadas no crânio, podendo ser primários (originados no sistema nervoso central) ou metastáticos, e classificados como benignos ou malignos conforme seu comportamento biológico (Louis et al., 2021). Sua gravidade varia conforme a localização, tipo celular e velocidade de crescimento (Cleveland Clinic, 2023). O diagnóstico precoce é essencial, mas desafiador devido à variedade de sintomas. Nesse contexto, exames de imagem são fundamentais para a detecção e avaliação da doença. Tumores se manifestam como áreas de hipo ou hiperintensidade, variando conforme a sequência utilizada, o que permite identificar suas características, conforme discutido em (Osborn, 2017). A Figura 1 compara uma imagem normal com outra contendo tumor (Figura 2). Observe que, na Figura 2, é possível identificar uma área na extremidade superior direita com grande intensidade, o que denota um possível tumor. Assim, esse padrão pode ser identificado pelos modelos.




Figura 1 – Ressonância magnética do cérebro normal (sem tumor).




Figura 2 – Ressonância magnética com presença de tumor cerebral.

3.2 Redes Neurais Convolucionais

As Redes Neurais Convolucionais (CNNs) foram desenvolvidas com o objetivo de analisar imagens e reconhecer automaticamente padrões relevantes, como bordas, formas e texturas, permitindo a classificação correta do que está presente em uma imagem. Elas foram introduzidas em 1998 por Yann LeCun e sua equipe, inicialmente para resolver o problema do reconhecimento de números manuscritos, utilizando uma base de dados chamada MNIST, que contém milhares de imagens de dígitos escritos à mão. O funcionamento das CNNs é baseado em uma estrutura de camadas, cada uma com um papel específico na análise da imagem.

A primeira etapa é a camada de convolução, onde filtros (também chamados de kernels) percorrem a imagem em pequenas regiões, detectando características

específicas. Cada filtro aprende a identificar um tipo de padrão visual, como linhas verticais ou formas arredondadas. Quando um filtro identifica algo relevante, ele gera um mapa de ativação, que destaca as áreas da imagem onde aquele padrão foi encontrado. Em seguida, entra em ação a camada de pooling, que serve para simplificar as informações extraídas. A forma mais comum é o max pooling, que reduz a dimensão dos mapas de ativação selecionando apenas os valores mais altos em pequenas áreas, preservando os elementos mais importantes e descartando os detalhes menos relevantes.

Por fim, as informações são processadas pela camada totalmente conectada (fully-connected), que reúne tudo o que foi aprendido nas etapas anteriores. Essa camada funciona como uma espécie de "tomada de decisão", transformando os dados em um vetor numérico que será usado para prever o que há na imagem. É nessa etapa que a rede determina, por exemplo, se uma imagem representa um gato, um número ou qualquer outro objeto. As CNNs se destacam por sua eficiência, pois conseguem reduzir significativamente a quantidade de parâmetros necessários para o treinamento, acelerando o processo de aprendizagem e tornando o modelo menos complexo, sem perder precisão.

4 METODOLOGIA

4.1 Arquitetura

Neste trabalho, a arquitetura proposta é composta por uma camada convolucional bidimensional que é responsável por extrair características locais das imagens médicas por meio de filtros que detectam padrões como bordas e texturas das imagens dos tumores. Após a convolução, aplica-se a normalização em lote, que estabiliza e acelera o treinamento ao padronizar as ativações, reduzindo variações numéricas internas da rede. Em seguida, a função de ativação ReLU introduz a não-linearidade ao modelo, permitindo o aprendizado de representações mais complexas ao manter apenas valores positivos. Posteriormente, a camada de max pooling reduz a dimensionalidade espacial, preservando as informações mais relevantes e removendo pequenas variações nas imagens que não são significativas para o modelo. Essa camada é importante para essa arquitetura, pois esse fator captura as características do tumor que mais se destacam na imagem, tornando mais fácil a predição da classe pelo modelo. Depois da aplicação do pooling, a saída será agrupada em apenas um vetor que será repassado a duas camadas de fully-connected, que será responsável por realizar a classificação da entrada. Por fim, é importante destacar que a arquitetura também possui um dropout de 50% para evitar enviesamento da rede no aprendizado do modelo, sendo que toda essa arquitetura é

demonstrada na Figura 2.




Figura 2– Arquitetura proposta.

5 EXPERIMENTOS E RESULTADOS

5.1 Base de Dados

A base de dados utilizada neste trabalho é intitulada de Brain MRI Images for Brain Tumor Detection, disponibilizada publicamente na plataforma Kaggle. Este conjunto de dados é composto por imagens de ressonância magnética cerebral, uma técnica de diagnóstico por imagem não invasiva, que utiliza campos magnéticos e ondas de rádio para gerar imagens detalhadas do cérebro. A ressonância magnética fornece maior contraste entre tecidos moles em comparação com a tomografia computadorizada, sendo especialmente eficaz na identificação de tumores, edemas, hemorragias e outras anomalias neurológicas. O conjunto é formado por 4.611 imagens, sendo 2.513 casos positivos (com tumor cerebral) e 2.098 casos negativos (sem tumor). As imagens foram rotuladas manualmente por um neurocirurgião especialista para garantir a acurácia dos diagnósticos.

5.2 Experimentos

Os experimentos foram conduzidos utilizando imagens redimensionadas para 255×255 pixels, a fim de padronizar a entrada da rede neural convolucional. Durante a fase de treinamento, foi adotado o otimizador Adam, conhecido por sua eficiência em

problemas com grandes volumes de dados e parâmetros (LOUIS, D. N.; PERRY, A.; WIESSENBURGER; et al). A função de perda utilizada foi a CrossEntropyLoss, adequada para tarefas de classificação multiclasse por considerar a distribuição probabilística das saídas (GOODFELLOW, I.; BENGIO, Y.; COURVILLE). Para garantir uma avaliação robusta do desempenho do modelo, o conjunto de dados foi dividido em subconjuntos de 75% da base de dados para treinamento e 25% para teste. A performance do modelo foi mensurada por meio de métricas amplamente utilizadas na literatura, como acurácia, precisão, sensibilidade (recall) e especificidade, permitindo uma análise abrangente tanto da capacidade preditiva quanto da confiabilidade do modelo em diferentes classes.

A arquitetura foi implementada utilizando a linguagem Python, escolhida por sua legibilidade, simplicidade e ampla utilização na comunidade de aprendizado de máquina. A biblioteca utilizada foi o PyTorch, uma das principais ferramentas de deep learning, conhecida por sua flexibilidade, suporte dinâmico a grafos computacionais.

5.3 Resultados

Após o treinamento do modelo de rede neural convolucional proposto, foi possível observar um desempenho satisfatório na classificação de imagens de ressonância magnética cerebral, conforme o resultado apresentado na Tabela 1. O modelo alcançou acurácia média de 97,13% no conjunto de teste, demonstrando sua capacidade de generalização e efetividade na tarefa de detecção de tumores.

Métrica	Valor (%)
Acurácia	97,13
F1 Score	97,00
Recall	97,00
Precisão	97,00

Tabela 1 – Métricas de avaliação do modelo proposto no conjunto de testes.

O modelo apresentou alta sensibilidade e especificidade, indicando bom desempenho na identificação de tumores e na redução de falsos positivos, aspectos cruciais em contextos médicos. No conjunto de teste, classificou corretamente 96,97% das imagens com tumor e 97,32% das saudáveis, com apenas 3,03% de falsos negativos e 2,68% de falsos positivos. Esses resultados, ilustrados na Figura 3, demonstram sua eficácia e confiabilidade no diagnóstico.

Também foi realizada a análise da curva ROC (Receiver Operating Characteristic), que permite avaliar a capacidade discriminativa do modelo em diferentes limiares de decisão. A curva ROC é traçada com base na taxa de verdadeiros positivos (TVP) contra a taxa de falsos positivos (TFP), possibilitando uma visão abrangente do desempenho do

classificador, conforme descrito por (Fawcett, 2006).

A métrica AUC (Área Sob a Curva ROC) obtida para o modelo proposto foi de 0.987, um valor bastante próximo do ideal (1.0). A AUC quantifica a performance geral do classificador em todos os possíveis limiares de decisão, representando a probabilidade do modelo classificar corretamente uma instância positiva como mais provável do que uma instância negativa, evidenciando uma excelente capacidade de discriminação entre as classes (FAWCETT, 2006). Esse resultado reforça que o modelo é eficaz mesmo quando o limiar de decisão é alterado, mantendo alta sensibilidade com baixa taxa de falsos positivos, conforme demonstrado na Figura 4.




Figura 3 – Matriz de confusão do modelo proposto no conjunto de testes.




Figura 4 – Curva ROC e da AUC do modelo proposto no conjunto de testes.

5.4 Interface com o Usuário

Para tornar o uso do modelo baseado em CNN acessível e intuitivo, foi desenvolvida uma aplicação web com interface gráfica amigável, permitindo que usuários interajam com o sistema sem a necessidade de conhecimentos técnicos em IA ou programação. A interface serve como ponte entre o usuário e o modelo proposto, oferecendo uma experiência fluida, informativa e responsiva, conforme demonstrado na Figura 5.




Figura 5 – Interface web para interação do usuário e o modelo proposto.

A aplicação web foi projetada com foco na usabilidade, utilizando tecnologias modernas de desenvolvimento frontend, como o uso da biblioteca React, combinadas com um backend robusto em Python utilizando o framework Django REST, que gerencia as requisições e integra diretamente com o modelo treinado.

Nessa interface, o usuário pode, por exemplo, enviar imagens de ressonância magnética, conforme pode ser visualizado na Figura 6, que serão processadas pelo modelo CNN. Após o envio, a imagem é encaminhada ao servidor, onde o modelo realiza a inferência, e o resultado é retornado de forma visual, por meio de mensagens informativas. Esse feedback é instantâneo e apresentado de maneira clara, o que melhora significativamente a experiência do usuário.




Figura 6 – Interface web para envio de imagens por parte do usuário.

Essa integração entre a interface e o modelo CNN transforma uma solução técnica em uma ferramenta interativa, funcional e utilizável em contextos reais, como diagnósticos médicos, classificação de objetos ou qualquer outro domínio em que o modelo tenha sido treinado.

6 ESTADO DA ARTE

Na literatura, já foram propostos variados modelos, tais como: VGG16 (Simonyan and Zisserman, 2014; Rathod et al., 2023), ResNet50 (He et al., 2016; Rathod et al., 2023), InceptionV3 (Szegedy et al., 2016; Rathod et al., 2023) e EfficientNet (Tan and Le, 2019; Rathod et al., 2023). Esses modelos vêm sendo amplamente aplicados em tarefas de classificação de tumores. Essa técnica permite que redes já treinadas em grandes bases de dados, como o ImageNet, sejam adaptadas para tarefas médicas com menor quantidade de imagens rotuladas, melhorando o desempenho dos modelos.

VGG16 é conhecida pela simplicidade e profundidade, utilizando camadas convolucionais sequenciais para extrair características detalhadas. ResNet50 introduz conexões residuais que facilitam o treinamento de redes profundas, evitando o problema do gradiente desaparecido. InceptionV3 combina convoluções de diferentes tamanhos em um único bloco, capturando informações em múltiplas escalas. EfficientNet equilibra profundidade, largura e resolução, alcançando alta precisão com menos parâmetros. Essas arquiteturas são amplamente usadas em tarefas médicas, como a classificação de tumores, por sua capacidade de adaptação a diferentes conjuntos de dados.

Estudos recentes, como o de (Rathod et al., 2023), demonstraram que o uso da EfficientNetV2 aplicada a imagens de ressonância magnética cerebral obteve altos índices de acurácia na detecção de tumores do tipo glioma, meningioma e pituitário. Da mesma forma, (Paul et al., 2022) empregaram uma combinação de ResNet e técnicas de fine-tuning para segmentação e classificação precisa de tumores cerebrais, obtendo resultados promissores. Além disso, (Khan et al., 2021) propuseram um modelo baseado em CNN com mecanismos de atenção, que melhorou a sensibilidade na detecção de tumores pequenos, mostrando o valor de abordagens híbridas.

Assim, para avaliar o desempenho do modelo proposto neste trabalho em comparação com arquiteturas encontradas na literatura, foi realizada uma análise experimental com base em métricas de classificação, por exemplo, acurácia. A Tabela 2 apresenta os resultados obtidos, evidenciando que o modelo proposto alcançou desempenho superior em termos de acurácia comparado a alguns dos modelos estudados, demonstrando sua eficácia na tarefa de detecção de tumores cerebrais. Observando essa tabela, é possível concluir que a arquitetura proposta apresentou um valor de acurácia superior aos demais modelos, exceto ao EfficientNet, pois este modelo usou a técnica de transfer learning, técnica de machine learning em que um modelo previamente treinado em uma tarefa com grande volume de dados, como classificação de imagens, é reutilizado em uma nova tarefa relacionada, geralmente com menos dados disponíveis. Tecnicamente, isso envolve o aproveitamento dos pesos já aprendidos pela rede neural, seja congelando as camadas iniciais e treinando apenas as finais, ou ajustando parte ou toda a rede com uma taxa de aprendizado menor. Essa abordagem acelera o treinamento, melhora o desempenho em situações com dados escassos e reduz o custo computacional, sendo amplamente usada em aplicações como visão computacional e processamento de linguagem natural. Em um trabalho futuro, pretendemos explorar também essa técnica.

Trabalho	Modelo	Acurácia
Simonyan and Zisserman, 2014	VGG16	96%
He et al., 2016	ResNet50	89%
Szegedy et al., 2016	InceptionV3	75%
Tan and Le, 2019	EfficientNet	99.69%
Este Trabalho	Arquitetura Proposta	97,13%

Tabela 2 – Comparação de Desempenho entre Modelos de CNN.

7 CONCLUSÃO

O presente estudo demonstrou o potencial da IA, especialmente das CNNs, na detecção de tumores cerebrais a partir de imagens de ressonância magnética. A arquitetura proposta, implementada com a biblioteca PyTorch, obteve resultados expressivos em métricas como acurácia, sensibilidade, especificidade, curva ROC e matriz de confusão, evidenciando sua eficácia na tarefa de classificação de imagens médicas. Além do bom desempenho técnico, a abordagem baseada em IA contribui significativamente para a redução da variabilidade diagnóstica entre especialistas, oferecendo um suporte padronizado, rápido e confiável para a tomada de decisão.

Embora os resultados sejam promissores, este trabalho reconhece a necessidade de ampliar o conjunto de dados utilizado, incorporando imagens com maior diversidade e complexidade, o que pode aprimorar ainda mais a robustez e a generalização do modelo. Futuras pesquisas podem também explorar o uso de técnicas complementares, como o aprendizado por transferência (transfer learning) e redes neurais mais profundas, além da integração com sistemas clínicos reais.

REFERÊNCIAS

CLEVELAND CLINIC. Brain Tumor: Symptoms, Causes, Diagnosis, and Treatment. Cleveland: Cleveland Clinic, 2023.

FAWCETT, T. An introduction to ROC analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861–874, 2006.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge: MIT Press, 2016.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition. In: *IEEE Conference on Computer Vision and Pattern Recognition*, 2016.

KHAN, H. A.; AKBAR, S.; SHAH, J. Attention-based Convolutional Neural Networks for Brain Tumor Classification and Segmentation, 2021.

LECUN, Y. et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, v. 86, n. 11, p. 2278–2324, 1998.

LOUIS, D. N.; PERRY, A.; WIESSENBURGER, D. D.; et al. The 2021 WHO Classification of Tumors of the Central Nervous System: A summary. *Acta Neuropathologica*, v. 142, p. 141–162, 2021.

MENZE, B. H. et al. The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS). *IEEE Transactions on Medical Imaging*, v. 34, n. 10, p. 1993–2024, 2015.

OSBORN, A. G. *Osborn's Brain: Imaging, Pathology, and Anatomy*. Elsevier, 2017.

PAUL, J.; DUBEY, S. R.; SINGH, S. K. Deep Residual Network with Transfer Learning for Brain Tumor Classification. *Computers in Biology and Medicine*, 2022.

RATHOD, P.; CHAUDHARY, A.; SHARMA, R. An Efficient Image Classification Technique using Transfer Learning Mechanism in the Context of Tumor Detection. *International Journal of Intelligent Systems and Applications in Engineering*, 2023.

RONNEBERGER, O. et al. U-Net: Convolutional Networks for Biomedical Image Segmentation. In: *MICCAI*, 2015.

SIMONYAN, K.; ZISSERMAN, A. Very Deep Convolutional Networks for Large-Scale Image Recognition. *arXiv preprint arXiv:1409.1556*, 2014.

SZEGEDY, C. et al. Rethinking the Inception Architecture for Computer Vision. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

TAN, M.; LE, Q. V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In: *International Conference on Machine Learning (ICML)*, 2019.

WORLD HEALTH ORGANIZATION. *Guide to Cancer Early Diagnosis*. Geneva: World Health Organization, 2017.